

每日三句精選 | Unlimited OCR 字幕總結

1. 影片背景：Baidu 開源 Unlimited OCR

原句

"A team at Baidu released a new open-source VLM called Unlimited OCR — you can take a long document and parse the entire thing in a single pass."

— YouTube: 技術測評影片

百度團隊開源咗 Unlimited OCR，號稱可以一次過 parsing 成份長文件，唔會越改越慢。

寫法分析

- 模型基礎：MoE 架構，3B 參數，500M active parameters。基於 DS OCR fine-tune
- GitHub 人氣：發佈一週已超過 12,000 stars
- 兩個模式：Gundam mode（高分辨率逐頁 tile 處理） vs Base mode（低分辨率全文件塞入 context）

商業應用

如果公司有大量文件需要 OCR，可以考慮用呢個本地模型做實驗，尤其係敏感文件唔想經雲端 API。

2. 三種 OCR 路線

原句

"These three approaches are still very much in use. It isn't really VLMs replacing traditional OCR — it's different options depending on the use case."

三條路線各有用途，唔係 VLM 取代一切。視乎場景揀工具先係正道。

寫法分析

- 傳統 OCR: Tesseract、PaddleOCR。Detect → Recognize pipeline。快、平、可 CPU 行、deterministic。適合乾淨簡單嘅文件
- Structure-aware Pipeline: Docling、PP-Structure。有 layout model + table model 保留結構。適合表格、發票、form
- Vision Language Model: Unlimited OCR 呢類。單一 model 直接睇成頁出 text。適合 messy / handwriting / 多變文件，但會 hallucinate

變體練習

- 選擇指南：文件乾淨→傳統OCR | 表格/發票→Structure-aware Pipeline | 混亂/手寫→VLM

3. Optical Compression

原句

"Take the page, render it as an image, compress it down into a very small number of vision tokens — you get the detail at a fraction of the cost."

將頁面 render 做圖片，再壓縮成極少量 vision token，用 1/16 token 成本保留高分辨率細節。

寫法分析

- 壓縮原理：頁面文字約 2,000 tokens → convert to vision tokens 慳 16 倍 cost

- 精確度：10x 壓縮保留約 97% accuracy，再壓縮會急降
- 5 個分辨率模式：Tiny (64t) → Base (256t) → Gundam (動態 tile 高分辨率)
- Baidu 限制：Unlimited OCR 只保留咗 Gundam 同 Base 兩個 mode

優化版本

"Optical compression is a neat trick — but it's not fully lossless. There's a sweet spot between compression and accuracy."

光學壓縮係聰明招數，但唔係無損。壓縮率同精確度之間有個 sweet spot。

4. KV Cache 樽頸

原句

"The KV cache grows with every single token the model generates. The more it writes, the bigger the cache gets, and the model literally slows down."

KV cache 隨 output token 越嚟越大，model 就越行越慢。呢個係長文件 single-shot 嘅真正樽頸。

寫法分析

- Input 問題已解決：DS OCR 用 optical compression 解決咗 input token 膨脹
- Output 問題先係牆：40 頁 transcription → KV cache 膨脹 → 變慢
- 現狀：論文表明無現有模型能 single-shot 超過 10 頁

商業應用

Document ingestion pipeline 用分頁 parallel processing 自然繞過呢個問題。Single-shot 只係跨頁表格、翻譯等 edge case 有價值。

5. RSWA (核心創新)

原句

"Every word can still look back at the entire page — the reference part. But when it looks back at already-written text, it only ever sees the last 128 words — the sliding window."

模型可睇返成頁 input (reference)，但睇返自己寫過嘅 text 時只睇最後 128 個字 (sliding window)。KV cache 保持 flat。

寫法分析

- 靈感來源：人手抄書：眼望 source，偶爾睇返最近幾句，其餘忘掉
- RSWA 機制：Reference = 整頁 compressed image tokens 全保留；Sliding window = 已寫 text 只留 128 tokens
- 效果：Memory flat, speed constant, 無論幾多頁
- 加速：超過 6,000 image tokens 嘅頁面，提速達 35%

優化版本

"RSWA is the one truly novel thing in this paper — memory stays flat and speed stays constant no matter how many pages you process."

RSWA 係呢篇論文唯一真正新嘅貢獻：無論處理幾多頁，memory 同 speed 都保持不變。

6. 現實限制

原句

"It's called Unlimited OCR. It's not actually unlimited. There is an input ceiling of 32,000 tokens."
叫 Unlimited，但唔係無限。Input 上限 32,000 tokens。

寫法分析

- Input 上限：32K tokens ceiling，測試過最多 40+ pages
- Gundam mode 限制：只能逐頁用，唔可以塞全文件；大文件要用 Base mode
- Benchmark：OmniDoc bench 93.9 排頂，但有同更近期 VLM 對比（Mistral OCR 4、Chandra 2、Qwen 2.5 Pro 等更高分）
- Chunking 優勢：分頁 parallel process → 無 KV cache 問題 → 更 scalable → 可 durable execution（失敗重試）

變體練習

- Single-shot 真正價值：跨頁 table / sentence 免拼接、pipeline 更簡單 — 但個 win 比宣傳窄好多

今日學習重點

概念	關鍵點	應用場景	難度
三種 OCR 路線	Traditional / Structure-aware / VLM	按文件類型揀	低
Optical Compression	頁→圖→vision token，慳 16x	輸入壓縮	中
KV Cache 問題	Output token 越多越慢	長文件 single-shot	高
RSWA	Reference page + 128-token sliding window	保持 flat memory & speed	高
現實限制	32K tokens 上限，非 accuracy leader	多數 case 揀 chunking pipeline	中

老師提示：Unlimited OCR 嘅 RSWA 係聰明設計，但 production 層面 parallel chunking 已解決大部分問題。Single-shot 價值只係跨頁 coherence（如跨頁表格、翻譯）。揀工具先睇場景，唔好被「Unlimited」呢個名吸引就盲目用。